Python応用（データ分析編）
3章演習
～グラフ描画トレーニング～

2022年9月15日

生田メディア支援事務室

3章演習　グラフ描画トレーニング

□ 3章で学んだ内容を用いて、実際のデータを分析してみましょう

① 東京の降水量を比較してみよう

② 日本の貿易内訳を知ろう

③ 企業を分析してみよう

© Meiji University,All rights reserved.

□ 表1は過去30年間の、表2は2021年の**東京における降水量**を表しています

- これらについて、データを**棒グラフ**で表し、比較してみましょう
- また、2つのデータからどんなことがわかるのか考えてみましょう

表1. 1991年から2020年までの東京の平均降水量(mm)

月	1月	2月	3月	4月	5月	6月	7月	8月	9月	10月	11月	12月
降水量(mm)	59.7	56.5	116.0	133.7	139.7	167.8	156.2	154.7	224.9	234.8	96.3	57.9

表2. 2021年の東京の降水量(mm)

月	1月	2月	3月	4月	5月	6月	7月	8月	9月	10月	11月	12月
降水量(mm)	43.5	88.5	173.0	156.0	99.5	168.5	310.0	382.5	222.5	199.5	93.0	54.5

© Meiji University,All rights reserved.

3章演習　グラフ描画トレーニング ①東京の降水量を比較してみよう -ヒント-　3

□ 以下の手順に沿って取り組んでみましょう

1. 参考：テキスト26ページ
2. X軸上の数値を決定しましょう
3. グラフの大きさを指定しましょう　※ここでは**(10,6)**としましょう
4. y1とy2が重ならないように、**wだけずらして**グラフを描画しましょう
   その他、**color,label,align**を設定しましょう
5. グラフのラベルを変更しましょう　※ラベルはコメントアウトしているものを使用してください

このようなグラフが12か月分作成されます。→

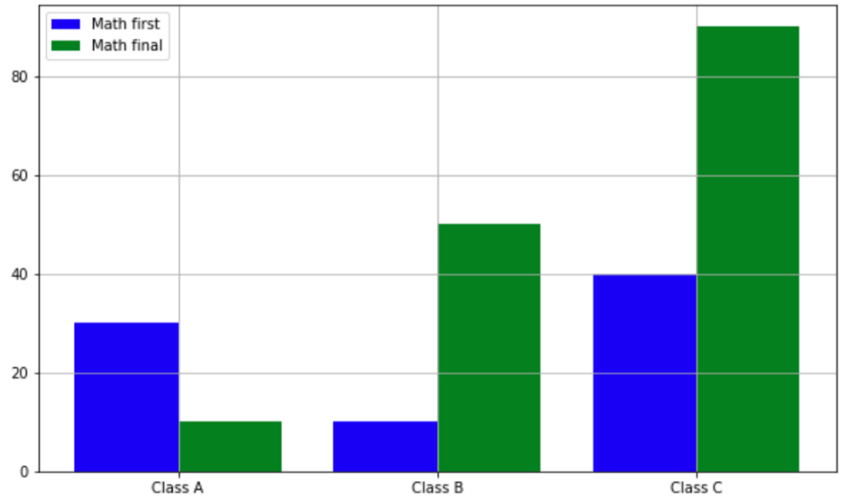

© Meiji University,All rights reserved.

□ 表3は2020年の日本の各国との貿易輸入額を表しています

- これらについて、データを円グラフで表し、比較してみましょう
- また、データからどんなことがわかるのか考えてみましょう

表3. 2020年の日本の貿易輸入額の大きい上位10ヵ国と総輸入額

相手国	CHN	USA	AUS	TWN	KOR	THA	VNM	DEU	SAU	ARE	OTH	SUM
輸入額(億円)	175,077	74,536	38,313	28,629	28,416	25,401	23,551	22,763	19,696	17,502	226,224	680,108

© Meiji University,All rights reserved.

□ 以下の手順に沿って取り組んでみましょう

1. 参考：テキスト28ページ
2. グラフの大きさを指定しましょう。　※ここでは**(8,8)**としましょう
3. グラフを描画しましょう
   size,labels,colors,counterclock,autopct,
4. 円を丸く描画しましょう

このようなグラフが”10カ国”と”その他”に
分割されて作成されます。→

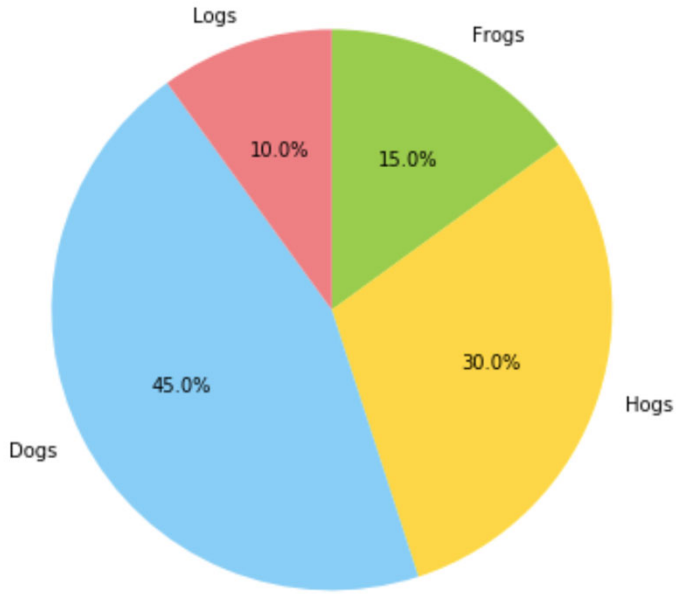

© Meiji University,All rights reserved.

□ 表4はある業界6社の財務情報を表しています

- これらについて、データをバブルチャートで表し、比較してみましょう
- また、データからどんなことがわかるのか考えてみましょう

表4. ある業界に属する6社の財務諸表

財務情報	A社	B社	C社	D社	E社	F社
売上高(百万円)	10,264,602	3,336,967	4,476,758	3,014,095	3,586,839	7,388,791
営業利益率(%)	7.19	4.76	5.63	4.40	6.11	4.84
時価総額(百万円)	6,414,556	2,486,212	3,054,394	1,402,448	3,994,100	2,805,996

© Meiji University,All rights reserved.

□ 以下の手順に沿って取り組んでみましょう

1. 参考：テキスト32ページ
2. グラフの大きさを指定しましょう。※ここでは**(10,6)**としましょう
3. 配列size全体を**1/10000倍**しましょう
4. 散布図を描画しましょう
   x,y,s,c,edgecolorsを設定しましょう

このようなグラフが6社分作成されます。→

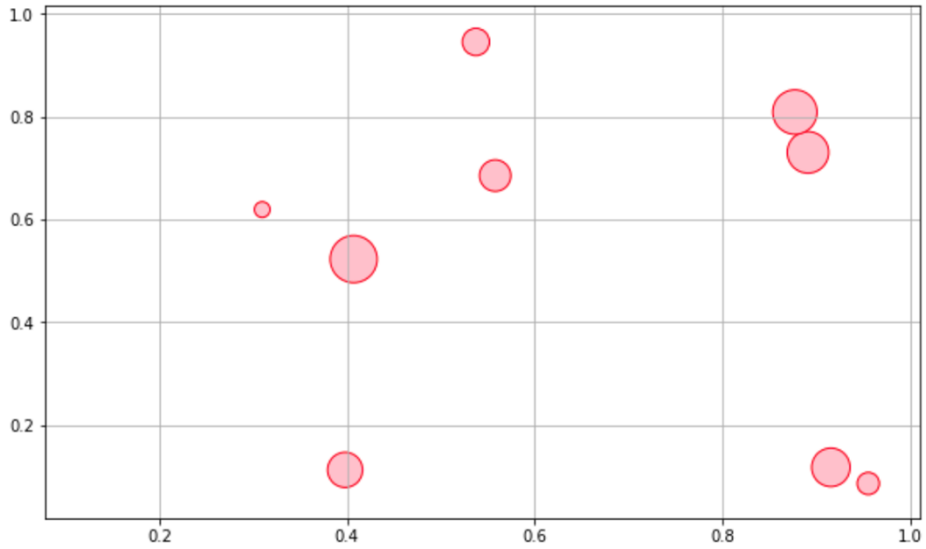

© Meiji University,All rights reserved.

3章演習　グラフ描画トレーニング ①東京の降水量を比較してみよう -解答例- 8

- **過去30年間と2021年の降水量のデータを棒グラフにまとめると、以下のようなグラフが描画できると思います**
  - 2021年は夏の降水量が例年の約2倍だったことがわかります

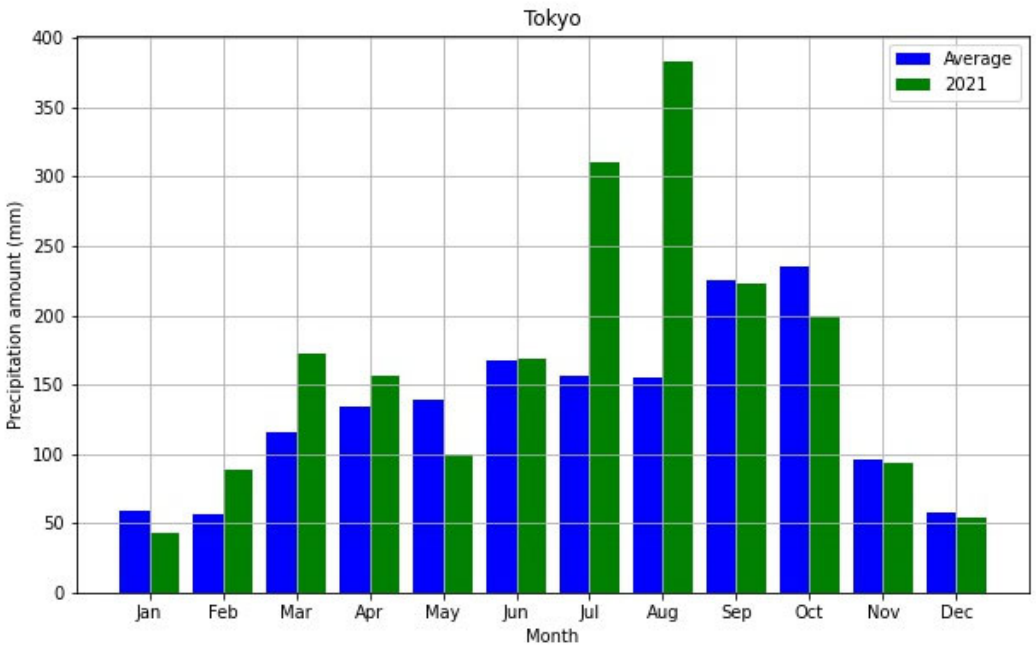

© Meiji University,All rights reserved.

2020年の貿易輸入の内訳を円グラフにまとめると、以下のようなグラフが描画できると思います

- 中国だけで全体の25%以上を占める
- 上位5か国で全体の半分以上を占めることなどがわかります

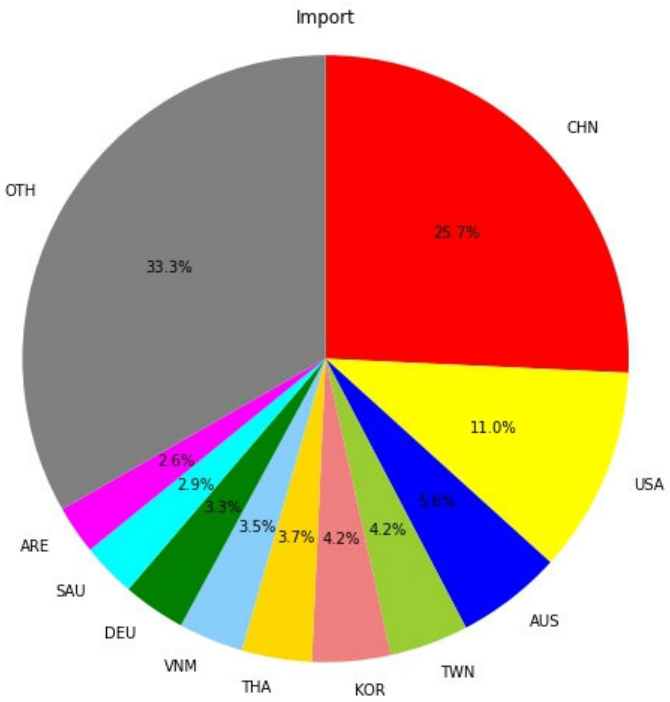

© Meiji University,All rights reserved.

□ 企業の財務情報をバブルチャートにまとめると、以下のようなグラフが描画できると思います

- A社は、売上高、営業利益率、時価総額のすべてにおいて他社を圧倒している
- E社とF社では、F社のほうが売上高は高いものの、営業利益率はE社のほうが高いといったことがわかります

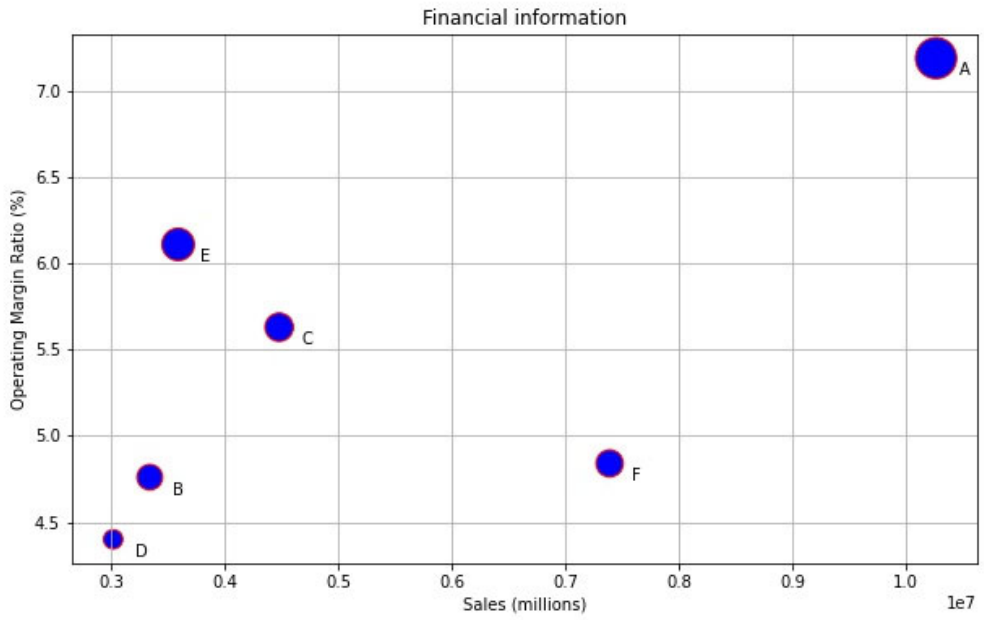

© Meiji University,All rights reserved.

□ 3章で学んだ様々なグラフから、目的に合わせてグラフを選択しましょう

- 棒グラフ
  →データを単純に並べて比較する
- 円グラフ
  →全体量に占めるデータの内訳を示す
- 散布図
  →二つのデータを相関を調べる
- バブルチャート
  →三つのデータを表現する
- ヒストグラム
  →データのばらつきを示す

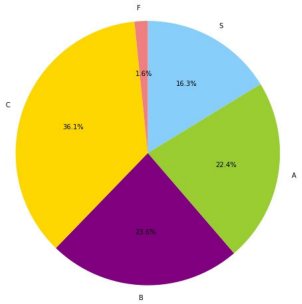

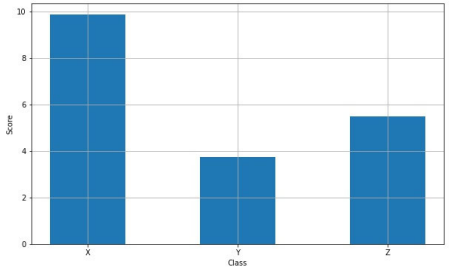

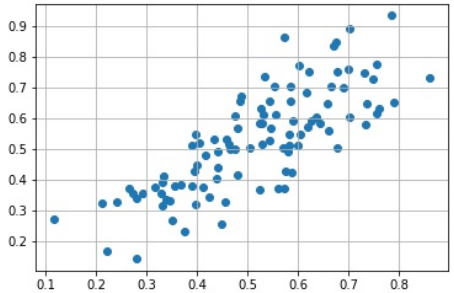

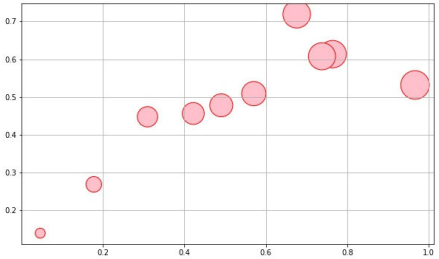

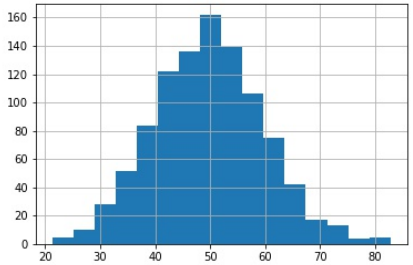

© Meiji University,All rights reserved.

Python応用（データ分析編）
5章演習 その1
～銀行のマーケティングキャンペーンデータ分析～

2022年9月15日

生田メディア支援事務室

5章で学んだ内容をおさらいしつつ、演習問題を解きましょう

- 演習問題ではbank-additional.csvのデータを使います。まずbank-additional.csvを読み込み、データの内容を確認しましょう
  - 詳細URL：https://archive.ics.uci.edu/ml/datasets/Bank+Marketing

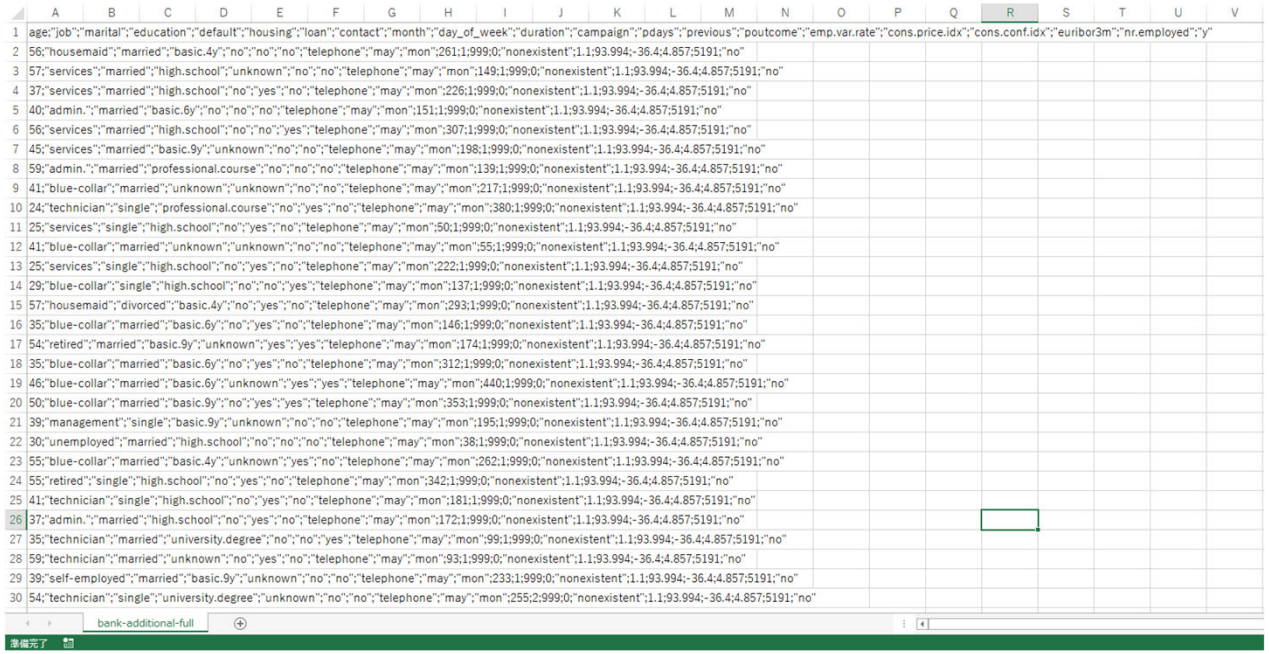

```
age;"job";"marital";"education";"default";"housing";"loan";"contact";"month";"day_of_week";"duration";"campaign";"pdays";"previous";"poutcome";"emp.var.rate";"cons.price.idx";"cons.conf.idx";"euribor3m";"nr.employed";"y"
56;"housemaid";"married";"basic.4y";"no";"no";"no";"telephone";"may";"mon";261;1;999;0;"nonexistent";1.1;93.994;-36.4;4.857;5191;"no"
57;"services";"married";"high.school";"unknown";"no";"no";"telephone";"may";"mon";149;1;999;0;"nonexistent";1.1;93.994;-36.4;4.857;5191;"no"
37;"services";"married";"high.school";"no";"yes";"no";"telephone";"may";"mon";226;1;999;0;"nonexistent";1.1;93.994;-36.4;4.857;5191;"no"
40;"admin.";"married";"basic.6y";"no";"no";"no";"telephone";"may";"mon";151;1;999;0;"nonexistent";1.1;93.994;-36.4;4.857;5191;"no"
56;"services";"married";"high.school";"no";"no";"yes";"telephone";"may";"mon";307;1;999;0;"nonexistent";1.1;93.994;-36.4;4.857;5191;"no"
45;"services";"married";"basic.9y";"unknown";"no";"no";"telephone";"may";"mon";198;1;999;0;"nonexistent";1.1;93.994;-36.4;4.857;5191;"no"
59;"admin.";"married";"professional.course";"no";"no";"no";"telephone";"may";"mon";139;1;999;0;"nonexistent";1.1;93.994;-36.4;4.857;5191;"no"
41;"blue-collar";"married";"unknown";"unknown";"no";"no";"telephone";"may";"mon";217;1;999;0;"nonexistent";1.1;93.994;-36.4;4.857;5191;"no"
24;"technician";"single";"professional.course";"no";"yes";"no";"telephone";"may";"mon";380;1;999;0;"nonexistent";1.1;93.994;-36.4;4.857;5191;"no"
25;"services";"single";"high.school";"no";"yes";"no";"telephone";"may";"mon";50;1;999;0;"nonexistent";1.1;93.994;-36.4;4.857;5191;"no"
41;"blue-collar";"married";"unknown";"unknown";"no";"no";"telephone";"may";"mon";55;1;999;0;"nonexistent";1.1;93.994;-36.4;4.857;5191;"no"
25;"services";"single";"high.school";"no";"yes";"no";"telephone";"may";"mon";222;1;999;0;"nonexistent";1.1;93.994;-36.4;4.857;5191;"no"
29;"blue-collar";"single";"high.school";"no";"no";"yes";"telephone";"may";"mon";137;1;999;0;"nonexistent";1.1;93.994;-36.4;4.857;5191;"no"
57;"housemaid";"divorced";"basic.4y";"no";"yes";"no";"telephone";"may";"mon";293;1;999;0;"nonexistent";1.1;93.994;-36.4;4.857;5191;"no"
35;"blue-collar";"married";"basic.6y";"no";"yes";"no";"telephone";"may";"mon";146;1;999;0;"nonexistent";1.1;93.994;-36.4;4.857;5191;"no"
54;"retired";"married";"basic.9y";"unknown";"yes";"yes";"telephone";"may";"mon";174;1;999;0;"nonexistent";1.1;93.994;-36.4;4.857;5191;"no"
35;"blue-collar";"married";"basic.6y";"no";"yes";"no";"telephone";"may";"mon";312;1;999;0;"nonexistent";1.1;93.994;-36.4;4.857;5191;"no"
46;"blue-collar";"married";"basic.6y";"unknown";"yes";"yes";"telephone";"may";"mon";440;1;999;0;"nonexistent";1.1;93.994;-36.4;4.857;5191;"no"
50;"blue-collar";"married";"basic.9y";"no";"yes";"yes";"telephone";"may";"mon";353;1;999;0;"nonexistent";1.1;93.994;-36.4;4.857;5191;"no"
39;"management";"single";"basic.9y";"unknown";"no";"no";"telephone";"may";"mon";195;1;999;0;"nonexistent";1.1;93.994;-36.4;4.857;5191;"no"
30;"unemployed";"married";"high.school";"no";"no";"no";"telephone";"may";"mon";38;1;999;0;"nonexistent";1.1;93.994;-36.4;4.857;5191;"no"
55;"blue-collar";"married";"basic.4y";"unknown";"yes";"no";"telephone";"may";"mon";262;1;999;0;"nonexistent";1.1;93.994;-36.4;4.857;5191;"no"
55;"retired";"single";"high.school";"no";"yes";"no";"telephone";"may";"mon";342;1;999;0;"nonexistent";1.1;93.994;-36.4;4.857;5191;"no"
41;"technician";"single";"high.school";"no";"yes";"no";"telephone";"may";"mon";181;1;999;0;"nonexistent";1.1;93.994;-36.4;4.857;5191;"no"
37;"admin.";"married";"high.school";"no";"yes";"no";"telephone";"may";"mon";172;1;999;0;"nonexistent";1.1;93.994;-36.4;4.857;5191;"no"
35;"technician";"married";"university.degree";"no";"no";"yes";"telephone";"may";"mon";99;1;999;0;"nonexistent";1.1;93.994;-36.4;4.857;5191;"no"
59;"technician";"married";"unknown";"no";"yes";"no";"telephone";"may";"mon";93;1;999;0;"nonexistent";1.1;93.994;-36.4;4.857;5191;"no"
39;"self-employed";"married";"basic.9y";"unknown";"no";"no";"telephone";"may";"mon";233;1;999;0;"nonexistent";1.1;93.994;-36.4;4.857;5191;"no"
54;"technician";"single";"university.degree";"unknown";"no";"no";"telephone";"may";"mon";255;2;999;0;"nonexistent";1.1;93.994;-36.4;4.857;5191;"no"
```

↑bank-additional.csvの内部

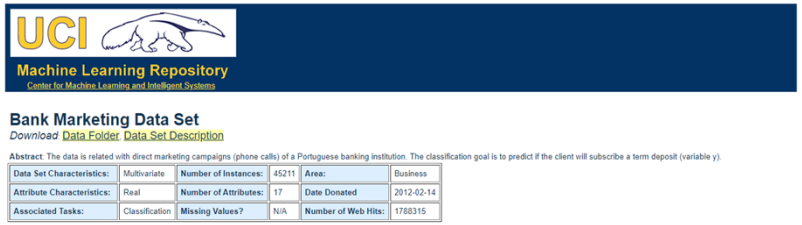

UCI Machine Learning Repository
Center for Machine Learning and Intelligent Systems

Bank Marketing Data Set

Download: Data Folder, Data Set Description

Abstract: The data is related with direct marketing campaigns (phone calls) of a Portuguese banking institution. The classification goal is to predict if the client will subscribe a term deposit (variable y).

Data Set Characteristics:	Multivariate	Number of Instances:	45211	Area:	Business
Attribute Characteristics:	Real	Number of Attributes:	17	Date Donated	2012-02-14
Associated Tasks:	Classification	Missing Values?	N/A	Number of Web Hits:	1788315

© Meiji University,All rights reserved.

元々読みづらいbank-additional.csvのデータを読みやすい形に整理し、出力してみましょう。

- 参考：テキスト48,49,50ページ

before

	age;"job";"marital";"education";"default";"housing";"loan";"contact";"month";"day_of_week";"duration";"campaign";"pdays";"previous";"poutcome";"emp.var.rate";"c
0	
1	
2	
3	
4	

after

	age	job	marital	education	default	housing	loan	contact	month	day_of_week	...	campaign	pdays	previous	poutcome	emp.var.rate
0	30	blue-collar	married	basic.9y	no	yes	no	cellular	may	fri	...	2	999	0	nonexistent	-1.8
1	39	services	single	high.school	no	no	no	telephone	may	fri	...	4	999	0	nonexistent	1.1
2	25	services	married	high.school	no	yes	no	telephone	jun	wed	...	1	999	0	nonexistent	1.4
3	38	services	married	basic.9y	no	unknown	unknown	telephone	jun	fri	...	3	999	0	nonexistent	1.4
4	47	admin.	married	university.degree	no	yes	no	cellular	nov	mon	...	1	999	0	nonexistent	-0.1

- 各ラベルのデータの意味を理解し、銀行のデータ分析に取り組んでみましょう

© Meiji University,All rights reserved.

各ラベルのデータの意味

age	int	年齢
job	varchar	職業
marital	varchar	未婚・既婚
education	varchar	教育水準
default	varchar	債務不履行があるか(yes/no)
housing	varchar	住宅ローン(yes/no)
loan	varchar	個人ローン(yes/no)
contact	varchar	連絡方法
month	char	最終コンタクト月
day_of_week	char	最終コンタクト日

duration	int	最終コンタクト時間(秒)
campaign	int	コンタクト回数
pdays	char	コンタクト後の経過日数
poutcome	char	前回キャンペーンの成果
emp.var.rate	int	雇用変動率
cons.price.idx	int	消費者物価指数
cons.conf.idx	int	消費者信頼感指数
euibor3m	int	欧州銀行間取引金利
nr.employed	int	被雇用者数
y	boolean	定期預金申し込み有無(1:有、0:無)

© Meiji University,All rights reserved.

次の演習に取り組んでみましょう

1. Loanがある人の数を確認しましょう。その数は？
   - 回答”no”・”yes”・”unknown”それぞれ何人ずついる？

2. Loanの分布を円グラフで示しましょう
   - 参考：テキスト59ページ

3. 消費者信頼感指数の最大値、最小値、平均値、中央値、最頻値を求めましょう

4. 消費者信頼指数と消費者物価指数の間にある関係性を調べてみましょう
   - 相関関係を描画してみましょう
   - 参考：テキスト57ページ
     - 散布図の描画について

© Meiji University,All rights reserved.

Python応用（データ分析編）
5章演習 その2
～タイタニック号の生存者分析～

2022年9月15日

生田メディア支援事務室

次の演習に取り組んでみましょう

タイタニック号に乗っていた乗客のデータから、生還した乗客にはどのような特徴があったのかを考察する

演習の手順

1. 配布された5章演習2問題ソースコード.ipynbを上から実行し、データの中身を確認してみましょう
2. 年齢の欠損値について平均で補完してみましょう
3. 今回使わないSibSp・parch・fare・Who・deckの列を削除してみましょう
4. 最後に、年齢、性別、チケットクラスがそれぞれ乗客の生存とどの程度関係していたのかを計算しましょう（年齢、性別、チケットクラスから1つ選択）

© Meiji University,All rights reserved.

タイタニックデータの中身を確認してみよう

- 演習用ファイルの変数「titanic」に格納されているタイタニック号の乗客データを表形式で表示してみましょう。
- 参考：テキスト49ページ

	survived	pclass	sex	age	sibsp	parch	fare	embarked	class	who	adult_male	deck	embark_town	alive	alone
0	0	3	male	22.0	1	0	7.2500	S	Third	man	True	NaN	Southampton	no	False
1	1	1	female	38.0	1	0	71.2833	C	First	woman	False	C	Cherbourg	yes	False
2	1	3	female	26.0	0	0	7.9250	S	Third	woman	False	NaN	Southampton	yes	True
3	1	1	female	35.0	1	0	53.1000	S	First	woman	False	C	Southampton	yes	False
4	0	3	male	35.0	0	0	8.0500	S	Third	man	True	NaN	Southampton	no	True

© Meiji University,All rights reserved.

□ データの説明

- タイタニック号とは？
  初めての航海中に氷山に衝突し沈没したイギリスの豪華客船。この事故の生還者は乗客約1500人のうち710人と言われており、20世紀最大の海難事故を起こした船として知られている。

- データの内容（主なものを抜粋）
  - Survived – 生存フラグ（0=死亡、1=生存）
  - Pclass – チケットクラス(1～3で小さければ小さいほど豪華に)
  - Sex – 性別
  - Age – 年齢
  - SibSp – タイタニックに同乗している兄弟/配偶者の数
  - parch – タイタニックに同乗している親/子供の数
  - fare – 料金

© Meiji University,All rights reserved.

□ 年齢の欠損値を補完してみよう

- 「titanic」に格納されている乗客の「age」データの欠損値を補完してみましょう

- 手順

1. まずは、欠損値があるか確認してみよう
2. 欠損値補完の関数を使ってみましょう
3. もう一度、欠損値があるか確認してみましょう

- ヒント
  - ▶ 欠損値の確認：テキスト72ページ
  - ▶ 欠損値の補完：テキスト73ページ
  - ▶ 平均値、中央値、最頻値の求め方：テキスト54ページ

© Meiji University,All rights reserved.

今回使わないデータを削除してみよう

- 「titanic」に格納されている乗客の「SibSp・parch・fare・Who・deck」列を削除してみましょう
- 参考：テキスト75ページ

	survived	pclass	sex	age	embarked	class	adult_male	embark_town	alive	alone
0	0	3	male	22.0	S	Third	True	Southampton	no	False
1	1	1	female	38.0	C	First	False	Cherbourg	yes	False
2	1	3	female	26.0	S	Third	False	Southampton	yes	True
3	1	1	female	35.0	S	First	False	Southampton	yes	False
4	0	3	male	35.0	S	Third	True	Southampton	no	True

注意

削除した列をもう一度削除しようとするとエラーになります。その場合は、もう一度データセットの読み込み部分から実行しなおしてください。

© Meiji University,All rights reserved.

自由に考察してみよう

- これまで整理してきた乗客データの「年齢、性別、チケットクラス」と生存フラグの相関を求めることで、生き残るための考察をしてみましょう

- 手順

1. 「年齢、性別、チケットクラス」から生存に関係ありそうだと思う要素を1つ選ぼう
2. 次のスライドを参照して相関を求め方を確認しよう
3. 関数から選んだ特徴と生存フラグがどの程度相関関係があるのか評価しよう

© Meiji University,All rights reserved.

自由に考察してみよう

- 各特徴と生存フラグの相関を求めよう
  - 年齢の場合

    量的変数とカテゴリ変数の相関であるので相関比を用いてみましょう

    相関比の求め方：correlation_v(生存フラグ列,age列)
  - 性別の場合

    名義尺度同士の相関であるのでクラメールの連関係数を用いて相関を求めてみましょう

    クラメールの連関係数：cramers_v(生存フラグ列,sex列)
  - チケットクラスの場合

    名義尺度と順位尺度の相関であるので順位相関比を用いて相関を求めましょう

    順位相関比： correlation_v(生存フラグ列,pclass列)

© Meiji University,All rights reserved.

考察例 各特徴と生存フラグの関係

- 年齢と生存フラグの相関

欠損値補完を行う前の年齢分布を見ると全体としての相関関係はないように見えます。
しかし可視化してみると0~10歳の子供の生存率が高いように見えます。
実際に　0~10歳の生存率とそれ以外の生存率を比べてみると、

0~10歳：61.29%
それ以外：38.65%

となり、「10歳以下の子供であるか」などは相関がありそうです。

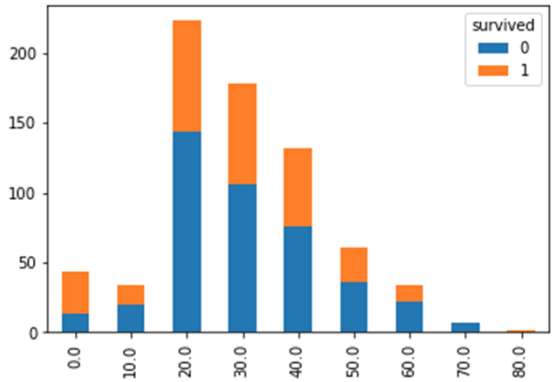

© Meiji University,All rights reserved.

考察例 各特徴と生存フラグの関係

- 性別と生存フラグの相関

クラメールの相関係数から相関があることが分かりました。そこで実際に可視化し、生存率を比べてみると、

女性：74.20%
男性：38.65%

となり女性のほうが生き残っていることがより分かります。

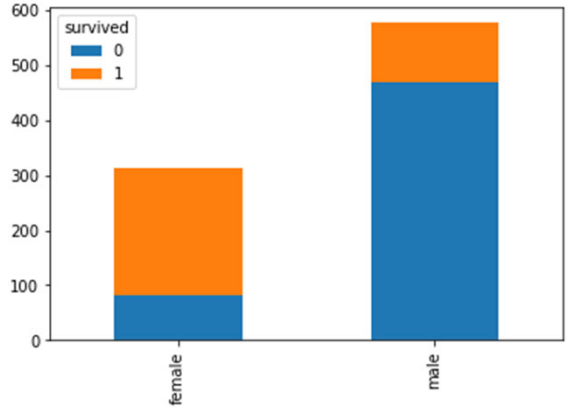

© Meiji University,All rights reserved.

考察例 各特徴と生存フラグの関係

- チケットクラスと生存フラグの相関

相関比を用いて計算すると相関があることが分かりました。
そこで実際に可視化し、生存率を比べてみると、

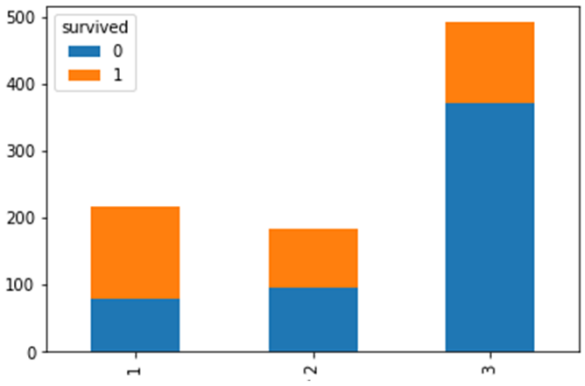

1クラス：62.96%
2クラス：47.28%
3クラス：24.24%

となりチケットのグレードが上がるにつれて生存率も上がっていることもわかりました。

© Meiji University,All rights reserved.

Python応用（データ分析編）
6章演習
～カフェ経営成功者への道～

2022年9月15日

生田メディア支援事務室

データの説明

- チップデータ
  - ディナーとランチの総支払額と含まれるチップの額が支払った人の性別や喫煙の有無などで分類されたデータ
  - 詳細URL： https://www.kaggle.com/datasets/ranjeetjain3/seaborn-tips-dataset

次の演習に取り組んでみましょう

- チップデータを可視化することでチップの額がどのような要因に大きく影響を受けるのか見てみましょう

© Meiji University,All rights reserved.

チップデータのロードと確認

- 配布されたソースコードを開き、必要なライブラリのインポートとチップデータの読み込みをしましょう
  - チップデータの内部を右下図のように出力し、内部を確認しましょう
  - 参考：テキスト48ページ

	total_bill	tip	sex	smoker	day	time	size
0	16.99	1.01	Female	No	Sun	Dinner	2
1	10.34	1.66	Male	No	Sun	Dinner	3
2	21.01	3.50	Male	No	Sun	Dinner	3
3	23.68	3.31	Male	No	Sun	Dinner	2
4	24.59	3.61	Female	No	Sun	Dinner	4

※チップデータ(一部)

© Meiji University,All rights reserved.

喫煙の有無とチップの額の関係

- stripplot 関数を用いて、喫煙の有無とチップの額の関係を見ていきましょう
  - 1変数の散布図を描画しましょう
  - 参考：テキスト81ページ

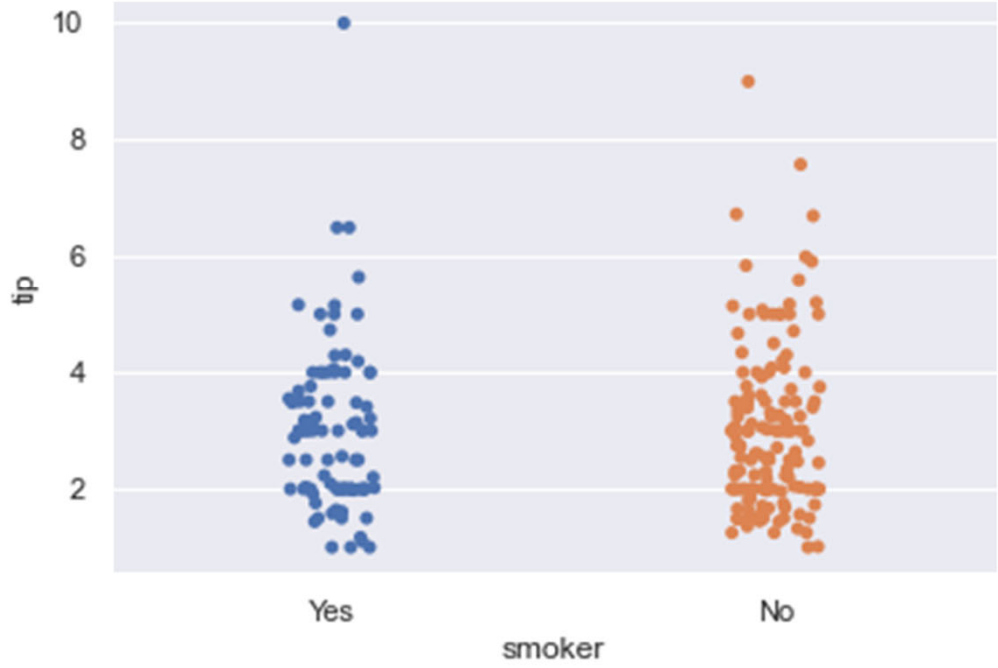

※完成イメージ

© Meiji University,All rights reserved.

□ 曜日とチップの額の関係

- violinplot 関数を用いて、曜日とチップの額の関係を見ていきましょう
  - ▶曜日によってチップの額の分布が変化するのか見てみましょう
  - ▶参考：テキスト83ページ

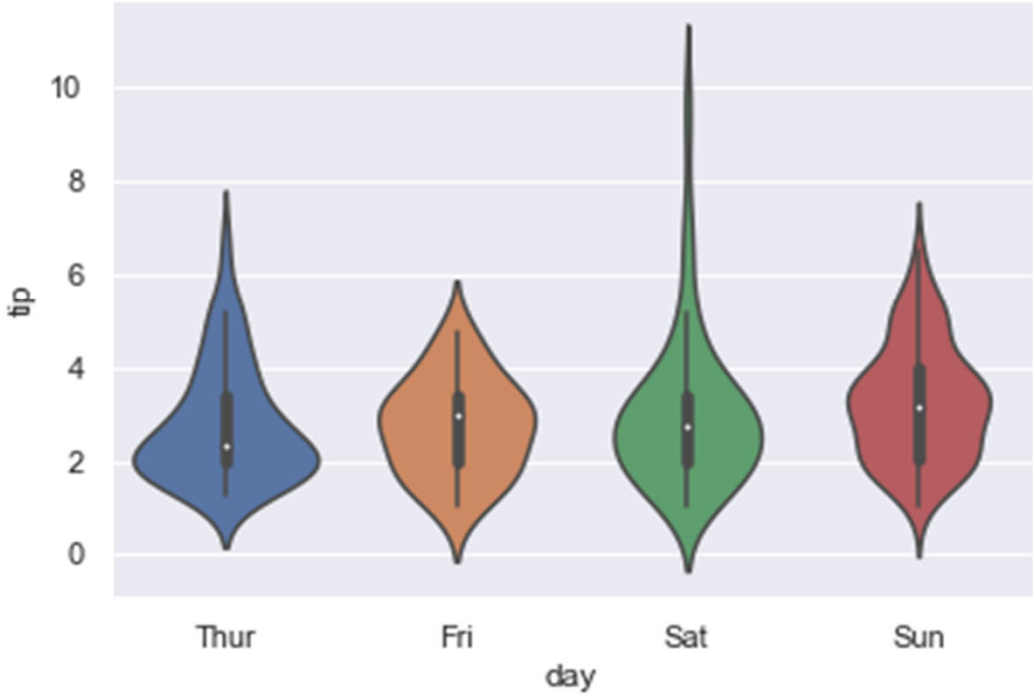

※完成イメージ

© Meiji University,All rights reserved.

各変数の関係

- pairplot 関数を用いて、各変数(支払総額、人数、チップの額)の関係を見ていきましょう
  - 各変数の散布図行列を見てみましょう
  - 参考：テキスト84ページ

- チップの額と最も相関のありそうな変数はどれでしょうか

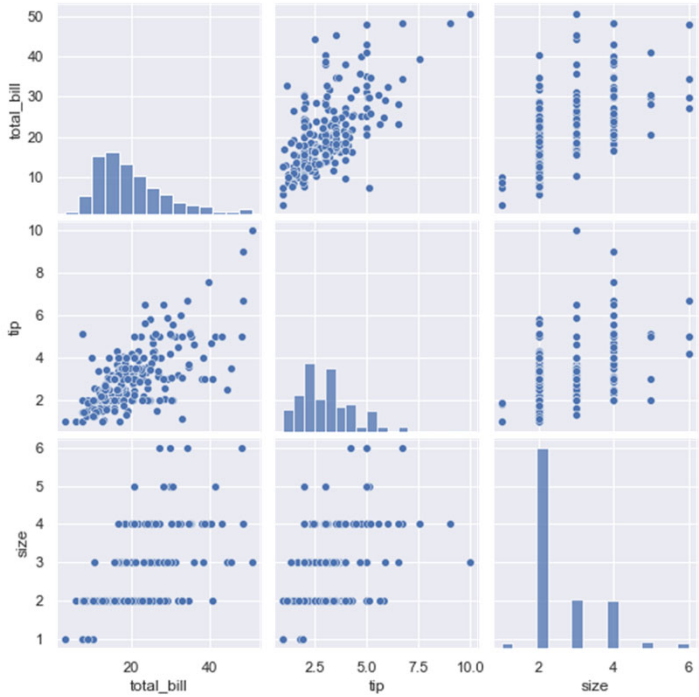

※完成イメージ

© Meiji University,All rights reserved.

□ 支払い総額とチップの額の関係

- 支払い総額とチップの額には相関がありそうでした
  - ▶“tip”と”total_bill”に関するグラフに注目(赤丸→)

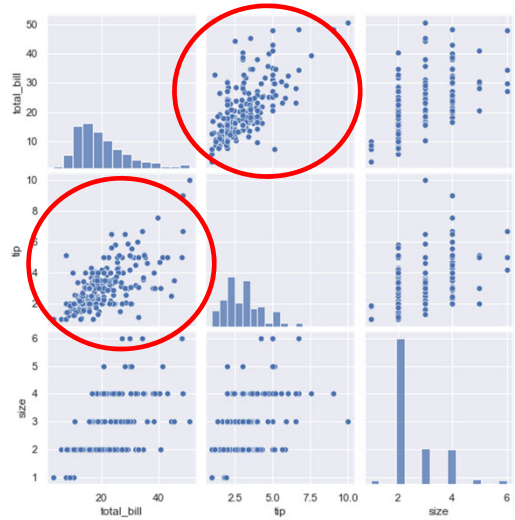

- では、男女の違いや昼食、夕食の違いでデータがどう変わるのか見てみましょう
  - ▶ヒント
    - ◆Scatterplot関数を用いて散布図を描画します
    - ◆関数の引数hueに”sex”や”time”を指定します

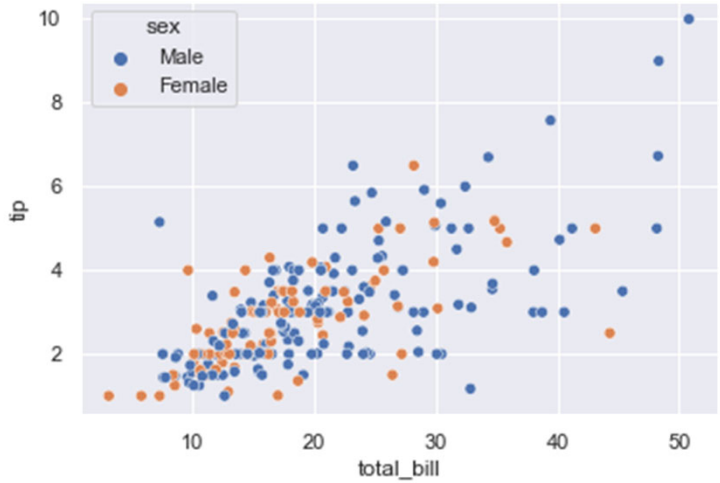

※完成イメージ

© Meiji University,All rights reserved.